

Análisis y Clasificación de Géneros Musicales con Modelos Clásicos y Modernos de Machine Learning

Patrick Ricardo Medina Reyes - 100 %

Ciencia de Datos, UTEC

Email: patrick.medina@utec.edu.pe

Hector Miguel Espinoza Torres - 100 %

Ciencia de Datos, UTEC

Email: hector.espinoza@utec.edu.pe

Franco Arturo La Rosa Cabrejos - 100 %

Ingeniería Civil, UTEC

Email: franco.larosa@utec.edu.pe

Juan Diego Jimenez Quispe - 100 %

Ingeniería Civil, UTEC

Email: juan.jimenez@utec.edu.pe

Resumen—En el presente proyecto se llevará a cabo el desarrollo e implementación de distintos modelos de clasificación de *Machine Learning*. Abordaremos desde la extracción de los datos de múltiples fuentes, preprocesamiento de estos, un análisis exploratorio, el modelado de distintas técnicas de clasificación tales como: *Regresión Logística*, *Support Vector Machines (SVM)*, *Multi Layer Perceptron (MLP)* y *ExtraTreesClassifier*. Finalizando con la evaluación de cada resultado obtenido, buscando las mejores valores de *Accuracy* y *F1-Score*

Index Terms—Machine Learning, Clasificación Musical, Multiclase, Validación Cruzada, SVM, MLP.

I. INTRODUCCIÓN

Hoy en día, con la producción a gran escala de contenido musical y su cada vez mayor complejidad acústica, ha ocasionado que sea un reto poder organizarla para aplicaciones de reproducción de músicas con la función de recomendación incluida. Por ende, un sistema que clasifique canciones según su género, es una herramienta pertinente. Con una máquina que pueda identificar el género de una canción mediante las características que esta presenta, optimizaría esta tarea. Nuestro objetivo final es que, mediante el uso de data extraída de distintas fuentes, preprocesada y escalada, entrenar distintos modelos para evaluar de forma rigurosa cual es el más preciso.

II. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

La data utilizada se divide en 6 géneros diferentes:

- 1) rock
- 2) classical
- 3) blues
- 4) disco
- 5) country
- 6) pop
- 7) salsa

En la Figura 1, se muestra la distribución de clases del dataset. Es importante destacar que la cantidad de datos por cada clase es bastante equilibrada. Esta distribución sugiere que el dataset no presenta un desbalance significativo de clases,

lo cual es positivo, ya que facilita que los modelos de clasificación, como SVM o MLP, logren un rendimiento adecuado sin que se vean sesgados hacia clases más representadas.




Figura 1. Distribución de clases del dataset.

La Figura 2 representa un gráfico de t-SNE, muestra que hay ciertos géneros musicales que se pueden diferenciar de buena manera como es el clásico. Algunos géneros, como rock, blues y disco, presentan puntos de datos dispersos que se solapan, lo que se puede inferir que son fáciles de confundirlos con otros géneros musicales. Esta dispersión puede generar ciertas dificultades en la clasificación de estos géneros debido a la alta similitud en sus características musicales. Aunque esto puede generar cierta imprecisión en la clasificación, no es un problema grave. Los modelos de clasificación pueden adaptarse a esta dispersión, ya que no impide que los géneros en su conjunto sean correctamente identificados. De hecho, una dispersión moderada puede ayudar a los modelos a generalizar mejor, ya que no se sobreajustan a patrones demasiado rígidos y permiten una mayor flexibilidad al clasificar datos nuevos.




Figura 2. Visualización t-SNE en 2D.

En la Figura 3, se nota que algunos géneros, como country, presentan una mayor dispersión en sus puntos de datos. Esta dispersión indica que las características de este género varían más entre las canciones, lo que podría hacer que el modelo encuentre más dificultades para identificar patrones consistentes. No obstante, esta dispersión no es lo suficientemente crítica como para comprometer el rendimiento general del modelo. Si bien puede afectar ligeramente la precisión de clasificación, especialmente en estos géneros más dispersos, los modelos todavía son capaces de capturar las tendencias generales, lo que evita una caída significativa en el accuracy.




Figura 3. Visualización UMAP en 2D.

III. PREPROCESAMIENTO Y FEATURE ENGINEERING

III-A. Recopilación de datos

Como primera parte para el desarrollo del proyecto, se abstrajo de dos maneras la data usada. Primero, se descargó del dataset de *GTZAN*, para tenerlo como una base. Posteriormente, esta se modificó al agregar canciones que fueron descargadas de forma manual además de eliminar ciertos registros, como duplicados y columnas innecesarias que estaban en el dataset, con el fin de mejorar el rendimiento teórico de los modelos. Obteniendo finalmente un total de 937 registros con 57 características y su etiqueta, de la cual un 80 % fue destinado para el entrenamiento y 20 % para la prueba.

III-B. Extracción de características

Con los fragmentos aleatorios de 30 segundos de cada canción se extrajeron sus características, tales como *Chroma STFT*, que es la información armónica; el *Root Mean Square (RMS)*, donde se mide la intensidad; el *Spectral Centroid*, que es la frecuencia según su magnitud; *Spectral Rolloff*, la cual es la frecuencia por debajo de la cual está; *Zero Crossing Rate (ZCR)*, que es la cantidad de veces que la señal fue cero; *Harmonic & Percussive*, que mide el componente más armónico y percusivo; *Tempo*, que es los golpes por minuto y está el *Mel-Frequency Cepstral Coefficients (MFCCs)*, que cada uno captura diferentes aspectos del espectro.

III-C. Normalización

La normalización de los datos es un paso muy importante, sobre todo para el desarrollo de modelos de *Machine Learning*, mediante la librería de *Scikit Learn*, con las funciones de *MinMaxScaler* y *StandardScaler*, con ambos métodos se probó cada uno de los modelos para seleccionar el que tenga mejores métricas.

III-D. Reducción de dimensionalidad

Se evaluó *Linear Discriminant Analysis (LDA)* con 6 componentes y *Principal Component Analysis (PCA)* con un 95 % de variación, para el entrenamiento de diferentes modelos, donde alguno de ellos mejoró su rendimiento. Además, se utilizó *t-Distributed Stochastic Neighbor Embedding (t-SNE)* y *Uniform Manifold Approximation and Projection (UMAP)* para tener una mejor visualización de la distribución de los datos. Sin embargo, estas no fueron de ayuda al momento de entrenar los modelos.

IV. METODOLOGÍA Y MODELOS UTILIZADOS

IV-A. Pipeline general

El pipeline aplicado en el proyecto siguió el siguiente flujo:

Datos → Escalamiento (MinMax / Standard) → PCA/LDA (opcional) → Modelos → Validación Cruzada → Métricas

Se realizó primero la separación entre características y etiquetas, seguida de un *train-test split* estratificado (80 % entrenamiento, 20 % prueba) para preservar la proporción de géneros en ambos subconjuntos. Sobre los datos de entrenamiento se ajustaron dos esquemas de normalización:

- *StandardScaler*: centra cada variable en su media y la escala por su desviación estándar. Resulta adecuado para modelos lineales y métodos que suponen datos normalizados, como *PCA* y *LDA*.
- *MinMaxScaler*: proyecta cada característica al rango [0, 1]. Es útil para redes neuronales, pues estabiliza los gradientes durante el entrenamiento.

Posteriormente, se evaluaron dos técnicas de reducción de dimensionalidad:

- *PCA (Principal Component Analysis)*: método no supervisado que proyecta los datos en componentes ortogonales preservando el 95 % de la varianza total. Permite eliminar ruido y redundancia.
- *LDA (Linear Discriminant Analysis)*: método supervisado que maximiza la separabilidad entre clases, proyectando los datos en un subespacio de dimensión $K - 1$ donde K es el número de géneros.

El conjunto de datos es relativamente balanceado: la clase con mayor número de muestras contiene 140 registros y la menor 139, lo que representa una diferencia aproximada del 0.8 %. Esta variación es insignificante desde el punto de vista estadístico, por lo que se consideró adecuado emplear métricas macro como *accuracy* y *F1-macro* sin técnicas adicionales de balanceo.

IV-B. Modelo base: regresión logística

La regresión logística se utilizó como modelo base debido a su sencillez e interpretabilidad. Se evaluó bajo dos configuraciones: únicamente con datos escalados mediante *StandardScaler*, y combinada con una proyección previa mediante *LDA*. Esta última permite trabajar en un subespacio supervisado donde las clases están mejor separadas.

El hiperparámetro principal, C , controla la regularización del modelo. Un valor pequeño impone mayor penalización y previene el sobreajuste. El mejor resultado se obtuvo con $C = 0,01$ (solver *lbfgs*), alcanzando un *accuracy* de 0.7447.

IV-C. Modelos adicionales

Se incluyeron dos modelos no lineales con el fin de capturar patrones más complejos en las características de las canciones:

- *Support Vector Machine (SVM)* con kernel *RBF*, adecuado para fronteras no lineales al proyectar implícitamente los datos a un espacio de alta dimensión.
- *Multilayer Perceptron (MLP)*, implementado en *PyTorch*, capaz de modelar relaciones no lineales profundas.

Estos modelos permiten determinar si la clasificación musical requiere fronteras de decisión más complejas que las que ofrecen los modelos lineales.

IV-C1. SVM + PCA: Debido a su sensibilidad al ruido y a la escala, el *SVM* fue entrenado sobre datos estandarizados y transformados mediante *PCA* preservando el 95 % de la varianza. Los hiperparámetros óptimos fueron $C = 10$ y $\gamma = 0,01$. Con esta configuración, el modelo alcanzó un *accuracy* de 0.7766, lo que evidencia que la tarea presenta fronteras no lineales.

IV-C2. Multilayer Perceptron (MLP): El *MLP* se entrenó sobre datos normalizados con *MinMaxScaler*. La arquitectura final incluyó varias capas densas con normalización por lotes (*Batch Normalization*), *dropout* progresivo, optimización mediante *AdamW*, ajuste adaptativo del *learning rate* y *early stopping*. Esta combinación permitió capturar relaciones complejas, obteniendo el mejor desempeño general con un *accuracy* de 0.8138.

IV-D. Modelo Moderno: ExtraTreesClassifier

Como modelo moderno basado en árboles se utilizó el *ExtraTreesClassifier*, un *ensemble* de múltiples árboles de decisión entrenados sobre la totalidad de los datos pero con umbrales de división altamente aleatorizados. A diferencia de un *Random Forest* tradicional, donde cada árbol busca el mejor punto de corte sobre un subconjunto de atributos, en *Extra Trees* los puntos de corte se eligen de forma aleatoria entre varios candidatos, lo que introduce más diversidad entre los árboles y ayuda a reducir la varianza del modelo.

En nuestro caso, se entrenó el modelo sobre las características previamente normalizadas con *StandardScaler* y las etiquetas codificadas mediante *LabelEncoder*. Se exploraron distintas configuraciones del número de árboles y del número de atributos considerados en cada división, seleccionando finalmente la siguiente configuración:

- Número de árboles: $n_estimators = 300$
- Selección de atributos por *split*: $max_features = "sqrt"$
- Semilla: $random_state = 42$

Con esta configuración, el modelo obtuvo:

- Accuracy: 0.76
- Precision macro: 0.76
- Recall macro: 0.76
- F1-Score macro: 0.76

Estos resultados sitúan al *ExtraTreesClassifier* como un modelo competitivo frente a los métodos clásicos, especialmente en géneros con mayor solapamiento espectral, aunque sin alcanzar el desempeño del *MLP*.

V. OPTIMIZACIÓN DE HIPERPARÁMETROS

V-A. Esquema de Validación

Todos los modelos clásicos fueron optimizados mediante *GridSearchCV* con validación cruzada k-fold ($k = 5$). Los *MLP* en *PyTorch* fueron optimizados mediante entrenamiento iterativo con *early stopping*.

V-B. Resultados de la Optimización

Cuadro I
HIPERPARÁMETROS ÓPTIMOS ENCONTRADOS

Modelo	Hiperparámetros probados	Mejor valor
Logistic Regression + LDA	$C \in \{0,01, 0,1, 1, 10, 100, 300, 1000\}$	$C = 0,01$ (<i>lbfgs</i>)
SVM + PCA	$C \in \{1, 10, 100\}$, $\gamma \in \{scale, 0,001, 0,01, 0,1\}$	$C = 10$, $\gamma = 0,01$
MLP (PyTorch)	LR $\in [0,0001, 0,001]$, profundidad y dropout	Acc = 0.8138
ExtraTreesClassifier	$n_estimators \in \{100, 200, 300\}$, $max_features \in \{sqrt, log2\}$	300, sqrt

VI. RESULTADOS

En esta sección se presentan los resultados obtenidos tras el entrenamiento de los cuatro modelos evaluados: regresión logística combinada con *LDA*, *SVM* con *PCA*, *ExtraTreesClassifier* y el *MLP* implementado en *PyTorch*. Se incluyen

las métricas globales, las matrices de confusión, un análisis cualitativo de los errores más comunes y una comparación general entre los modelos.

VI-A. Métricas de desempeño

La Tabla II resume las métricas macro de cada modelo. El *MLP* alcanzó los mejores valores de *precision*, *recall* y *F1-score*, mientras que el *SVM* con *PCA* fue el mejor modelo clásico no lineal.

Cuadro II
COMPARACIÓN DE MODELOS USANDO F1-MACRO

Modelo	Precision	Recall	F1-Macro
Regresión logística (Standard + LDA)	0.74	0.73	0.73
SVM (Standard + PCA)	0.77	0.77	0.77
MLP (MinMax)	0.82	0.81	0.81
ExtraTreesClassifier	0.76	0.76	0.76

VI-B. Matrices de confusión

Las matrices de confusión permiten identificar cómo se comporta cada modelo para cada género musical. Se observa un desempeño consistentemente alto en *classical* y mayores dificultades en géneros como *rock*, *blues* y *disco*, los cuales presentan una fuerte superposición en las visualizaciones *t-SNE* y *UMAP*.




Figura 4. Matriz de confusión – regresión logística + LDA.




Figura 5. Matriz de confusión – SVM + PCA.




Figura 6. Matriz de confusión – ExtraTreesClassifier.




Figura 7. Matriz de confusión – MLP PyTorch.

VI-C. Análisis de errores

El análisis de los errores revela patrones coherentes:

- El género *classical* presenta altos niveles de discriminación debido a su estructura armónica más definida.
- Géneros como *rock*, *blues* y *disco* muestran tasas de error más elevadas, lo que corresponde a su solapamiento en el espacio de características.
- El género *country* presenta mayor variabilidad interna, generando dispersión en espacios reducidos como *PCA* y *UMAP*.

Estos resultados reflejan las limitaciones de los descriptores tradicionales, que capturan bien características globales pero no necesariamente timbres e instrumentaciones específicas.

VI-D. Comparación global

Los resultados permiten establecer una jerarquía clara:

- La regresión logística combinada con *LDA* muestra que existe una separabilidad moderada mediante fronteras lineales.
- El *SVM* con kernel *RBF* captura relaciones no lineales que permiten una mejora sobre el modelo base.
- El *ExtraTreesClassifier* logra un rendimiento competitivo, aunque limitado por la aleatoriedad de las divisiones.
- El *MLP* demuestra la mayor capacidad para modelar patrones complejos y se posiciona como el mejor clasificador del estudio.

VI-E. Curvas de entrenamiento del MLP

El entrenamiento del *MLP* mostró convergencia estable y ausencia de sobreajuste severo gracias al uso combinado de normalización, *dropout*, regularización y *early stopping*. La Figura 8 ilustra la evolución de la pérdida durante el entrenamiento.




Figura 8. Curva de pérdida del MLP durante el entrenamiento.

VI-F. Análisis por Clase

El análisis detallado de las métricas por clase permite identificar comportamientos particulares:

- *classical*: mayor precisión y recall en todos los modelos.
- *disco* y *rock*: sistemáticamente las clases con mayor confusión.
- *salsa*: presenta buen desempeño relativo, posiblemente por su carácter rítmico más marcado.

Estas observaciones son coherentes con la estructura acústica de cada género y refuerzan la necesidad de modelos más expresivos para capturar matices que los descriptores espectrales tradicionales no representan completamente.

VII. CONCLUSIONES

- En base a los resultados obtenidos, el modelo que tuvo mejores resultados fue el de *Multi Layer Perceptron*, ya que presenta mejores métricas al ser un modelo que mejor se adapta a una data más compleja como esta.
- La data se presenta como solapada ya que, hay varias canciones donde son de más un género, tiene una intensidad, tiempos o alguna de las características similares. Los modelos, al no poder diferenciar otros aspectos fundamentales de una canción como instrumentos por ejemplo, se le dificulta poder entrenarse de la manera más óptima.

VII-A. Trabajos futuros

- El uso de un espectrograma, recurso visual en donde se puede visualizar del audio, sería de gran utilidad para complementar la investigación, mediante modelos de *Convolutional Neural Network* (CNN), donde este modelo, mediante aprendizaje de patrones en estas imágenes, tendría mejores resultados.
- Vemos pertinente para un futuro el uso de más géneros musicales para enriquecer la data. Sin embargo, también es muy necesario ver que canciones se están cargando, pues durante el desarrollo se encontraron muchas canciones donde los géneros eran similares entre sí.

REFERENCIAS

- [1] S. Shalev-Shwartz y S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, 2014. [En línea]. Disponible en: <https://www.cs.huji.ac.il/~shais/UnderstandingMachineLearning/understanding-machine-learning-theory-algorithms.pdf>
- [2] G. Tzanetakis y P. Cook, "Musical genre classification of audio signals," *IEEE Transactions on Speech and Audio Processing*, vol. 10, n.º 5, pp. 293–302, 2002. [En línea]. Disponible en: <https://ieeexplore.ieee.org/document/1021072>

Link del repositorio: Repositorio de GitHub.