

Análisis y Clasificación de Géneros Musicales con Modelos Clásicos y Modernos de Machine Learning

Patrick Ricardo Medina Reyes Héctor Miguel Espinoza Torres
Franco Arturo La Rosa Cabrejos Juan Diego Jiménez Quispe

Universidad de Ingeniería y Tecnología (UTEC)
Ciencia de Datos & Ingeniería Civil

24 de noviembre de 2025

Contenido

- 1 Motivación y Problema
- 2 Dataset y Análisis Exploratorio
- 3 Preprocesamiento y Características
- 4 Metodología y Modelos
- 5 Resultados
- 6 Conclusiones y Trabajos Futuros


- Producción masiva de contenido musical y creciente complejidad acústica.
- Necesidad de organizar y clasificar canciones para sistemas de recomendación (Spotify, YouTube Music, etc.).
- Problema: asignar automáticamente el género musical de una canción a partir de sus características de audio.
- Tipo de problema: **clasificación multiclase** de géneros musicales.

Objetivo del proyecto

- Extraer, limpiar y preprocesar datos musicales provenientes de múltiples fuentes.
- Entrenar y evaluar distintos modelos de clasificación:
 - Regresión Logística
 - Support Vector Machines (SVM)
 - Multi Layer Perceptron (MLP, PyTorch)
 - ExtraTreesClassifier
- Comparar el desempeño usando métricas globales (Accuracy, F1-macro).
- Identificar el modelo que mejor se adapta a la naturaleza del problema.

- Base inicial: *GTZAN*, usada como referencia clásica en clasificación musical.
- Extendido con canciones descargadas manualmente y limpieza de:
 - Registros duplicados.
 - Columnas innecesarias.
- **Tamaño final:** 937 canciones.
- **57 características** numéricas + etiqueta de género.
- **7 géneros:** rock, classical, blues, disco, country, pop, salsa.

Distribución de géneros



- Dataset prácticamente balanceado.
- Mayor clase: 140 muestras.
- Menor clase: 130 muestras.
- Diferencia relativa: $\approx 0,8\%$.
- → Desbalance no significativo.

Figura: Distribución de clases del dataset.

Visualización de los datos




Figura: Visualización UMAP en 2D. Permite observar la estructura global del dataset y la dispersión entre géneros.

Visualización de los datos




Figura: Visualización t-SNE en 2D. Resalta las agrupaciones locales y solapamientos entre géneros similares.

Extracción de características

- Se utilizan fragmentos aleatorios de **30 segundos** por canción.
- Características extraídas (ejemplos):
 - Chroma STFT (información armónica).
 - RMS (intensidad de la señal).
 - Spectral Centroid y Spectral Rolloff (brillo y energía).
 - Zero Crossing Rate (ZCR).
 - Componentes Harmonic & Percussive.
 - Tempo (golpes por minuto).
 - MFCCs (*Mel-Frequency Cepstral Coefficients*).
- Total de **57 características** numéricas por canción.

Preprocesamiento y reducción de dimensionalidad

- **Normalización:**

- *StandardScaler*: centra y escala por desviación estándar (adecuado para modelos lineales, PCA y LDA).
- *MinMaxScaler*: escala al rango $[0, 1]$ (adecuado para redes neuronales, estabiliza gradientes).

- **Reducción de dimensionalidad:**

- *PCA* (no supervisado): preserva el 95 % de la varianza.
- *LDA* (supervisado): proyecta a un subespacio de dimensión $K - 1$.
- *t-SNE* y *UMAP*: usados únicamente para **visualización**, no para entrenar modelos.

Pipeline general

Datos → Escalamiento (MinMax / Standard) → PCA/LDA
(opcional)
→ Modelos → Validación Cruzada → Métricas

- **Train-test split** estratificado (80 % train, 20 % test).
- Uso de **accuracy** y **F1-macro** por tratarse de un problema multiclase balanceado.
- Comparación entre modelos lineales, no lineales y basados en árboles.

- **Modelo base: Regresión Logística + LDA**
 - Sencillez e interpretabilidad.
 - LDA mejora separabilidad lineal entre géneros.
- **Modelos Adicional:**
 - **SVM (kernel RBF) + PCA:** fronteras de decisión no lineales.
- **Modelo Adicional:**
 - **MLP (PyTorch):** varias capas densas, batch normalization, dropout, optimizador AdamW y early stopping.
- **Modelo moderno basado en árboles:**
 - **ExtraTreesClassifier:** árboles extremadamente aleatorizados.

Optimización de hiperparámetros

- **Modelos clásicos:** GridSearchCV con validación cruzada k-fold ($k = 5$).
- **MLP (PyTorch):** entrenamiento iterativo con early stopping.
- Búsqueda de:
 - C en Regresión Logística y SVM.
 - γ en SVM.
 - Número de capas, neuronas, dropout, learning rate en MLP.

Modelo	Mejor configuración
Logistic Regression + LDA	$C = 0,01$ (lbfgs)
SVM + PCA	$C = 10$, $\gamma = 0,01$
MLP (PyTorch)	Mejor Acc. test $\approx 0,8138$
ExtraTreesClassifier	$n_{\text{estimators}} = 300$, $\text{max_features} = \text{"sqrt"}$

Cuadro: Comparación de modelos usando F1-Macro

Modelo	Precision	Recall	F1-Macro
Regresión Logística (Standard + LDA)	0.74	0.73	0.73
SVM (Standard + PCA)	0.77	0.77	0.77
MLP (MinMax)	0.82	0.81	0.81
ExtraTreesClassifier	0.76	0.76	0.76

- El **MLP** presenta el mejor desempeño global.
- SVM + PCA es el mejor modelo clásico no lineal.
- ExtraTreesClassifier obtiene resultados competitivos.

Matrices de confusión (1/2)




Figura: Regresión Logística + LDA.




Figura: SVM + PCA.

Matrices de confusión (2/2)




Figura: ExtraTreesClassifier.




Figura: MLP (PyTorch).

Curva de entrenamiento del MLP




Figura: Curva de pérdida del MLP durante el entrenamiento.

- Convergencia estable sin signos de sobreajuste severo.
- Entrenamiento optimizado mediante normalización, dropout, regularización y early stopping.

Conclusiones

- El **MLP** fue el modelo con mejor desempeño global en términos de F1-macro.
- LDA y PCA contribuyeron a mejorar el rendimiento de los modelos clásicos al reducir ruido y redundancia.
- Se observa solapamiento fuerte entre géneros como rock, blues y disco, lo que limita la separabilidad perfecta.
- Los descriptores espectrales capturan bien características globales, pero no todos los matices de timbre e instrumentación.

Trabajos futuros

- Uso de **espectrogramas** y modelos de tipo **Convolutional Neural Network (CNN)**.
- Integrar información temporal y frecuencial de manera conjunta.
- Ampliar el conjunto de géneros y número de canciones, cuidando la calidad de las etiquetas.
- Implementar un prototipo de **sistema de recomendación musical** utilizando el mejor modelo.

¡Gracias!